Wstęp

Wstęp

Spis treści

Rozdział 1.

Wprowadzenie do fingerprintingu

1.1. Podstawowe pojęcia

1.1.1. Nomenklatura używana w tej pracy

Pisząc o odcisku palca użyto (także w tytule pracy) ogólnie przyjętego skrótu myślowego, oznaczającego odbitkę linii papilarnych, czyli formę językową uznawaną za poprawną przez specjalistów od daktyloskopii.

Użycie formy językowej „odcisk palca” w terminie „cyfrowy odcisk palca” ma wiele sensu. Jeszcze bez zdefiniowania tego specjalistycznego terminu, możemy domyślić się, co oznacza. Oczywiście wynika to z faktu, że cyfrowy odcisk palca i analogowy odcisk palca są ze sobą w pewien sposób powiązane (koncepcja cyfrowego odcisku palca czerpie z wartości wynikających ze stosowania odbitek ludzkich linii papilarnych w dziedzinie kryminalistyki).

Angielskie słowo „fingerprint” tłumaczy się jako odcisk palca, jednakże w zagranicznych publikacjach dotyczących cyfrowego odcisku palca rzadko występuje termin „digital fingerprint”. Kontekst użycia jest na tyle wyraźny, że użycie samego „fingerprint” jest wystarczające.

Zachodnie nazewnictwo ma tę przewagę, że jest zdecydowanie bardziej kompaktowe. Także w przypadku słowotwórczego zabiegu *fingerprinting*, oznaczającego czynność; szukając polskiego odpowienika musielibyśmy sięgnąć po „cyfrowe znakowanie”. Z uwagi na tę kompaktowość i łatwość użycia, w pracy preferowane będzie użycie oryginalnej nomenklatury.

1.1.2. Definicje

W kolejnych punktach zawarto najważniejsze definicje i powiązane pojęcia, które będą używane w przeciągu całej pracy.

Fingerprint

Wektor cech pozwalający zidentyfikować dowolny zbiór danych.

Aby fingerprint pełnił praktyczną funkcję identyfikacyjną, tak jak odbitka ludzkich linii papilarnych pełni praktyczną funkcję identyfikacyjną, często stosuje się algorytm, który kojarzy wektor cech z określonej długości (zwykle krótkim) ciągiem bajtów (identyfikatorem; można go także rozumieć jako etykieta). Takim algorytmem może być na przykład wysokiej wydajności funkcja skrótu (niekoniecznie zdatna do zastosowań kryptograficznych—na przykład MurmurHash). W niektórych źródłach można także spotkać się z taką definicją, że fingerprint to już sam wynik wyżej wspomnianego algorytmu. Taka definicja nie zmienia istoty fingerprintu, ale jest zdecydowanie mniej przydatna w kontekście fingerprintingu urządzeń podłączonych do Internetu i przeglądarek internetowych, czego dotyczy niniejsza praca.

Fingerprint urządzenia podłączonego do Internetu

Wektor cech pozwalający zidentyfikować urządzenie podłączone do Internetu.

Instalacja przeglądarki internetowej

Instalacja na konkretnym urządzeniu. W przypadku zmiany ustawień, konfiguracji i liczby pluginów oraz aktualizacji przeglądarki, instalacja przeglądarki pozostaje ciągle tą samą instalacją.

Fingerprint przeglądarki internetowej

Wektor cech pozwalający zidentyfikować instalację przeglądarki internetowej.

1.1.3. Właściwości fingerprintu

Ludzkie linie papilarne są na ogół niepowtarzalne, niezmienne i nieusuwalne. Z wartości wynikających ze stosowania ich odbitek w swojej dziedzinie badawczej czerpie (także etymologicznie) koncepcja fingerprintu i dlatego też fingerprint z dobrze dobranymi cechami będzie odzwierciedlać podobne właściwości.

W przypadku fingerprintingu urządzeń podłączonych do Internetu i przeglądarek internetowych najważniejszymi ich właściwościami są unikalność / różnorodność (niepowtarzalność) oraz stabilność (niezmienność), przy czym zwiększenie unikalności lub stabilności ma najczęściej negatywny wpływ na drugi parametr.

Jedną ze stosowanych[1] metod pomiaru unikalności fingerprintu urządzeń i przeglądarek jest entropia Shannona.

Entropia Shannona

Wartość entropii można rozumieć jako liczbę pytań binarnych potrzebnych do sklasyfikowania losowo wybranego elementu z danego zbioru. Zatem entropia Shannona zbioru D z etykietami $\{l_0, l_1, \ldots, l_{n-1}\}$ wyraża się wzorem

$$H(D) = -\sum_{i=0}^{n-1} p(l_i) \log_2 p(l_i)$$

gdzie $p(l_i)$ to wyrażona ułamkiem częstość $x \in D$ mającego etykietę l_i. W przypadku w którym każda etykieta występuje tak samo często entropia ma wartość maksymalną równą $\log_2 n$.

Przykład Jeśli zbiór fingerprintów przeglądarek internetowych ma 32 bity entropii, to w przypadku losowego wyboru jednego z nich oczekujemy, że w najlepszym przypadku tylko 1 na 4294967295 przeglądarek będzie miała taki sam fingerprint.

[1] Metrykę tę stosowało na przykład badanie „How Unique Is Your Web Browser?" Electronic Frontier Foundation; w momencie pisania pracy jedno z największych badań tego typu.

Stabilność

W przypadku dodania kolejnej cechy do wektora cech, identyfikującego urządzenie lub przeglądarkę, zwykle zwiększy to entropię, ale także zmniejszy stabilność fingerprintu. Dzieje się tak ponieważ jest to kolejna rzecz, która może zmienić się w czasie. Jeśli jedną z cech wejściowych jest wersja oprogramowania urządzenia lub wersja przeglądarki (która zwykle zmienia się parę razy w ciągu roku), to kolejne fingerprinty mogą odbiegać od siebie i naiwny klasyfikator, korzystający z algorytmu reagującego na najmniejsze zmiany (na przykład funkcja skrótu), mógłby nadać takiemu urządzeniu/przeglądarce kolejną etykietę, zamiast potraktowania jej jako poprzednio widzianą instalację.

1.2. Fingerprinting a Internet

Aby lepiej zrozumieć istotę fingerprintu i motywację stojącą za stosowaniem fingerprintingu w kontekście urządzeń podłączonych do Internetu oraz przeglądarek internetowych, wspominając o różnych innych obszarach przetwarzania komputerowego w których wykorzystywany jest fingerprinting w stosownych mu celach, kolejne punkty posłużą jako referencja (także historyczna).

1.2.1. Początki Internetu

Początek Internetu jaki znamy obecnie, to początek stworzonej w 1969 roku na potrzeby amerykańskiego wojska sieci ARPANET. ARPANET była implementacją koncepcji rozproszonych sieci cyfrowych transmisji danych Paula Barana z 1962 roku. Na samym początku swojego istnienia, Internet wykorzystywany był do tego aby rozpraszać obliczenia pomiędzy wiele komputerów—w tym wypadku chodziło o superkomputery znajdujące się w innych ośrodkach badawczych (ARPANET powstało na Uniwersytecie Kalifornijskim w Los Angeles). W tym samym okresie powstawały inne globalne sieci komputerowe, zapoczątkowane zwykle w innym celu (na przykład komunikacyjnym, rozrywkowym), które później połączono z ARPANET. Badacze historii Internetu wskazują na fakt, iż gwałtowny rozwój Internetu zawdzięcza się właśnie komunikacyjnemu i rozrywkowemu aspektowi konkurencyjnych sieci.

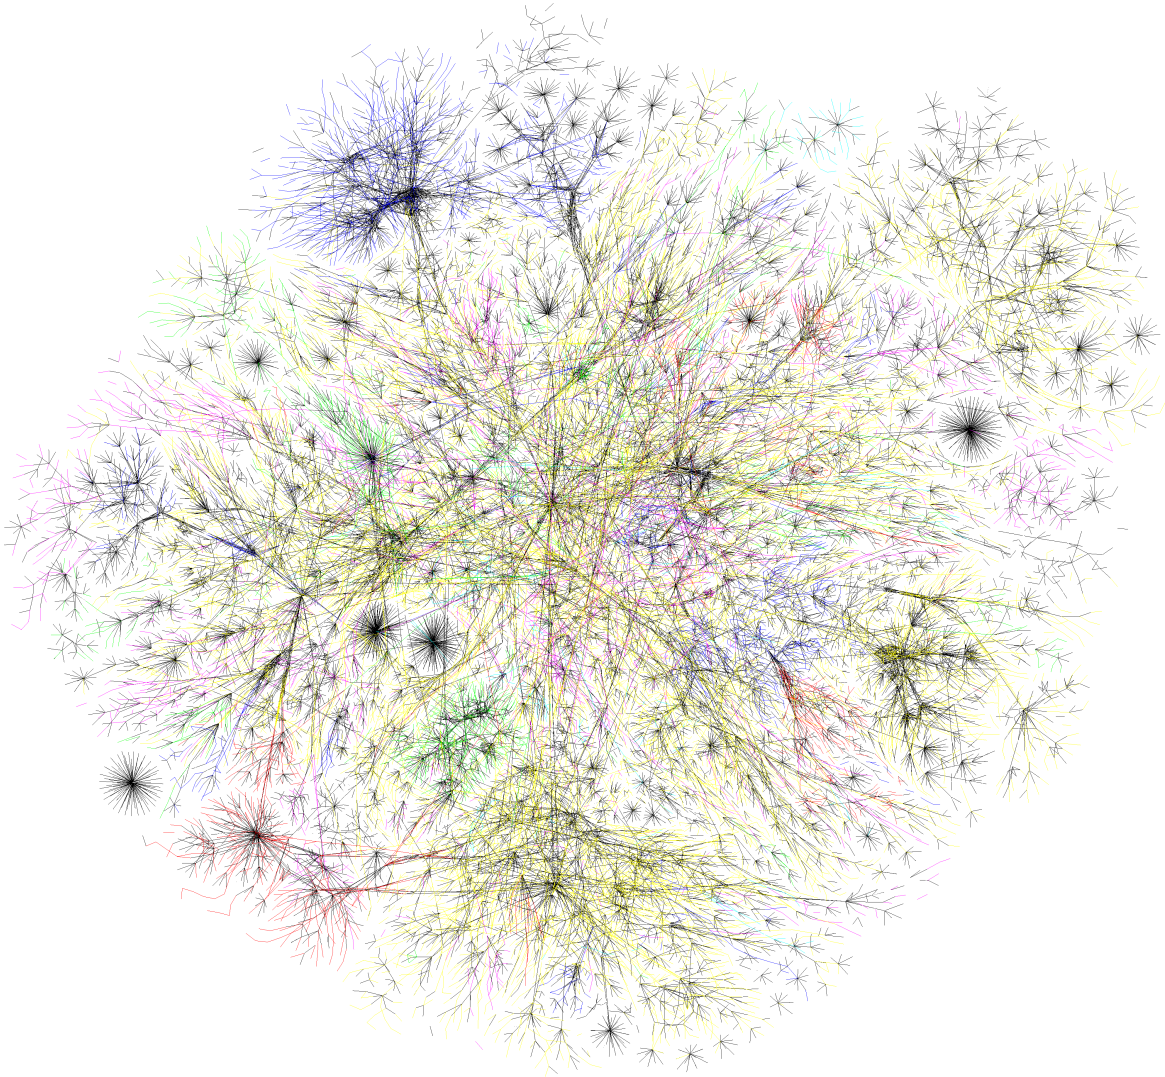

Źródło: http://www.opte.org/maps/ (odwrócono kolory w celu zaoszczędzenia tuszu)

Rysunek 1: Mapa Internetu z 16 stycznia 2005 roku.

1.2.2. Założenia funkcjonowania Internetu i ich realizacja

Po tym jak w 1989 Tim Bernes-Lee oraz Robert Cailliau utworzyli projekt sieci dokumentów hipertekstowych, czyli tego, co obecnie znamy jako World Wide Web i strony internetowe, osoby prywatne oraz instytuje komercyjne zaczęły dostrzegać korzyści z użytkowania Internetu, a szczególnie z wykorzystania go jako medium reklamy i sprzedaży. Zniesienie zakazu wykorzystywania Internetu do celów zarobkowych w 1991 roku zakończyło chwilę w której Internet był medium naukowego dyskursu i zapoczątkowało okres istnienia Internetu dla mas, który trwa do dziś.

Perspektywa techniczna

Podstawą struktury obecnego Internetu jest model TCP/IP i konceptualnie składa się ze współpracujących ze sobą 4 warstw:

1. dostępu do sieci
2. kontroli transportu
3. Internetu
4. aplikacji

W najwyższej z warstw, czyli warstwie aplikacji działają takie usługi jak przeglądarka czy serwer WWW. To najbardziej interesująca warstwa z perspektywy niniejszej pracy, ale fingerprinting urządzeń podłączonych do Internetu może odbywać się także w niższych warstwach.

Początki śledzenia użytkowników Internetu

. . .

1.3. Fingerprinting w branży komputerowej

Fingerprinting to technika wykorzystywana w wielu obszarach w dyscyplinie informatyki; fingerprinting urządzeń podłączonych do Internetu i przeglądarek internetowych to tylko pewien wycinek zastosowań tej koncepcji. O ile podane na początku

tego rozdziału definicje ujmują fingerprint w sposób ogólny i także taki, który pokrywa się z definicjami, które można znaleźć w publikacjach dotyczących fingerprintingu urządzeń i przeglądarek, to definicje dotyczące zastosowań fingerprintu innych bytów mogą być bardziej specyficzne czy też mogą eksponować inne właściwości, charakterystyczne dla stosownych zastosowań. Kolejne punkty służą jako referencja do ukazania jak szeroko wykorzystywana jest omawiana koncepcja.

1.3.1. Fingerprinting audio, wideo i algorytmy ACR

Metody fingerprintingu akustycznego i cyfrowych materiałów wideo, znane także jako algorytmy Automatic Content Recognition (ACR), powstały ze względu na potrzebę kontroli treści umieszczanych w serwisach internetowych pod kątem potencjalnych naruszeń praw do wykorzystania. Algorytmy Automatic Content Recognition są sparametryzowane w podobny sposób, co algorytmy fingerprintingu urządzeń i przeglądarek, czyli istotny jest balans pomiędzy niepowtarzalnością a stabilnością fingerprintu. Fingeprint audio lub wideo musi działać w podobny sposób do zachowania ludzkiego moderatora, czyli w przypadku kiedy materiał jest nieodróżnialny dla ludzkiego ucha lub oka jako ten, wobec którego przeprowadzany jest proces rozpoznawania, to powinien on zostać oflagowany.

1.3.2. Fingerprinting klucza publicznego

Spis rysunków

Spis tablic